文献综述智能体设计说明

大模型智能体长期记忆综述项目

成员 A　成员 B　成员 C

2026 年 10 月

1　设计目标与约束

本智能体的任务：围绕研究问题 “大模型智能体如何从持续交互中保留有用经验，在信息变化时正确更新记忆，并在后续任务中可靠地使用这些记忆”，完成一篇不少于 30 篇真实文献的综述的全部可自动化环节——检索、去重、筛选、证据提取、陈述登记与草稿生成。

核心约束（对应课程要求）：

- **真实性优先**：任何引用、摘录、数值必须可回查到原文；禁止编造。宁可输出 “待核验”，不输出无依据结论。
- **可恢复**：跨运行保留研究状态，中断后可继续且不重复写入。
- **人工节点**：真人核验不可替代；智能体只准备核验材料，不代签、不预填 “已通过”。

2　架构

```
        /          /
             |
    Agent  coordinator.py
         (RQ     /        ) ->          ->      ->
             |
                                /    /
search: OpenAlex / arXiv / Crossref / Semantic Scholar
dedup:  DOI / arXiv ID /     -    -                -> work_id
fetch:  PDF     (sha256     ) + pdftotext          + HTML
evidence/claims/memory/review: JSONL
```

```
checks:          /          /
                 |
        data/*.jsonl + runs/<id>/events.jsonl
                 |
           +          +
```

两层运行形态（决策记录 `docs/decisions.md` D-2）：

- **协调器回合**（G2 演示）：模型在工具循环中自主决策——观察缺口、选择检索词、读页、提交证据、诚实报告失败；
- **批处理管线**（G3 规模化）：逐篇单次模型调用提取证据，与协调器共用同一套摘录验证器与数据格式。

3 记忆设计

四类记忆（`memory_events.jsonl`，追加事件式）：任务记忆（范围/协议/待办）、证据记忆（定位/摘录/解释）、决策记忆（筛选理由/修改原因）、经验记忆（流程总结，默认未经事实核验）。

两类状态分离记录：

- `valid_status`: active / superseded / disputed / rejected——有效性；默认检索过滤非 active；
- `trust_status`: unverified / source_checked / human_verified——核验层级；草稿与模型推测不得自动升级。

更新采用 `supersedes` 事件链：新条目取代旧条目但历史完整保留，可审计 “旧错误经摘要后失去来源” 的路径。冲突不按时间新旧自动覆盖：研究范围变更可更新任务规则；两篇论文结论不同则保留各自实验条件并标记差异。

4 反幻觉机制与实测

4.1 机制

摘录提交时的**逐字签名验证**（代码强制，不依赖模型自觉）：

1. 摘录与页面提取文本各生成 “签名”——剔除空白与连字符（排版产物）后的字符序列；
2. 摘录签名必须是页面签名的**连续子串**；

3. 通过后回存**原文真实片段**（保留原始连字符与换行），保证 `evidence.excerpt` 与提取文本逐字一致；
4. 失败则拒绝并返回页面上最相似的原文片段（相似度提示），供模型自纠错重试。

改写、缩写、省略号压缩、凭记忆复述、表格单元格拼接均会被拒绝。

4.2 实测统计（真实运行日志汇总）

运行形态	摘录被拒	摘录接受
协调器回合（G2，12 次运行）	258	38
批处理管线（G3 深读）	102	313

表 1: 逐字验证拦截统计（真实运行日志汇总，`runs/`）。协调器早期回合的高拒绝率来自验证规则迭代（连字符/双栏问题修复前）与早期提示词不成熟；被拒摘录从未进入证据库。独立抽查：随机 4 条证据回查原 PDF 页，4/4 摘录逐字存在。

协调器回合中两次典型的真实决策（`runs/` 日志可回查）：

- **缺口驱动**：模型观察到 RQ1/RQ5 证据不足后，自主选择 7 个补充检索词（如 "long-term memory versus context window RAG parametric knowledge boundary"），非脚本预设；
- **诚实失败**：工具链缺少证据枚举能力时，模型拒绝编造 evidence_id，明确报告 "在禁止编造约束下无法合规完成" 并提出工具改进建议（后被采纳实现）。

5 人工核验节点

- 核验包生成器（`review_queue`）从真实数据产生三层待办：文献身份/版本核验（每项候选引用文献）、边界判定复核（模型纳入/ 排除决策）、claims 复核（direct/synthesis 全部）；
- 核验结果由真人写入 `data/reviews.jsonl`，智能体不预填 "已通过" 记录；
- 优先级标注：更新与可靠性分支（综述重点）为 P0。

6 评估设计

12 个冻结案例（`evaluation/cases.jsonl`）× 三条件（A 无记忆基线 / B 上下文注入 / C 结构化记忆）：跨会话恢复、失效记忆处理、不确定性保留、跨运行任务四类各 3 例。评分规则见 `evaluation/rubric.md`。

6.1 结果（自动检查指标，36/36 完成）

指标	A（无记忆）	B（上下文注入）	C（结构化记忆）
编造标识案例数	3	3	**1**
失效内容采用	0	0	0
honesty 缺口标注	3/3	2/3	3/3
跨会话恢复（recovery）	2/3	3/3	**3/3**
跨运行任务（multirun）	1/3	0/3	**3/3**
失效记忆处理（supersede）	3/3	3/3	2/3

表 2: 自动检查结果（`evaluation/results.jsonl`，真实运行）。C 条件唯一的编造标记为模型在澄清反问中使用 “W0028” 作为标识格式示例（非事实引用，自动检查无法区分，人工复核确认）。

发现：结构化记忆（C）在编造与跨会话恢复/多运行任务上优于无记忆基线（A）与朴素上下文注入（B）；B 在 honesty 案例中因全部历史平铺而漏标缺口。**已知混杂**：C 使用工具循环（多轮检索），A/B 为单次调用——优势不能完全归因记忆机制本身；小样本（12×3）不构成统计证据。

失效内容采用为 0 的说明：指纹检查的实体名窗口误报已修复（跳过前两个窗口）；拒绝性提及（“不使用 v1 的 X”）仍可能命中，自动标记一律按 rubric 交人工复核。

6.2 过程完整性

评估经历两轮实现修复（记忆检索对中文失效、失效记忆过滤缺陷），每次修复后全量重跑并在 `docs/decisions.md` D-4/D-5 记录；受污染的早期结果归档为 `results_*.bak`，未计入报告。

7 局限

- 摘录验证保证 “摘录逐字来自所指页面”，不保证 “解释无过度引申”——语义层核验仍需真人；
- 页级定位基于 pdftotext raw 模式的页序，与印刷页码可能不一致（预印本无印刷页码）；核验包中保留原文 PDF 供人工对页；
- 批处理管线的分支标注与矩阵分类由模型判定，属待复核信息（已列入核验队列）；
- 评估为小样本演示性评估（12 案例 × 3 条件），不构成方法优劣的统计证据。