大模型智能体的长期记忆：组织、更新与可靠性评测综述

王佳伟　刘圣涵

2026 年 10 月

摘要

大语言模型智能体在跨会话、长期任务中需要外部记忆以保留经验、跟踪状态并复用知识。本文综述 LLM 智能体长期记忆的组织、更新与可靠性评测：基于三源检索与两阶段筛选（691 项候选经题名摘要初筛与正文深读，40 篇核心阅读池、39 项进入正文引用），从生命周期视角梳理研究脉络。主要发现：（1）组织与检索机制的增益高度依赖任务与设置——图结构记忆在 LongMemEval 上的 token F1（0.417）低于匹配预算的扁平向量基线（0.468），结构化组织并非必然优于扁平存储；（2）遗忘与更新是低成本可行操作（一次图剪枝移除 9.8% 节点而 token F1 变化不显著），但存在信息损失与误删权衡；（3）错误写入、摘要失真、错误检索与错误使用构成独立于恶意攻击的可靠性问题，且幻觉在多阶段流水线中沿传播链累积；（4）评测从会话长度转向能力维度（知识更新、弃答），但“更新正确性”与“记忆何时真正有帮助”仍缺乏统一的成本—收益度量。综述同时给出一个以逐字证据验证与人工核验节点约束幻觉的综述智能体实现及其小规模评估。局限：领域以近期预印本为主，结论的条件性强，人工核验进行中。

关键词：大语言模型；智能体；长期记忆；记忆更新；可靠性；评测

1　引言

大语言模型（Large Language Model, LLM）驱动的智能体在长期交互任务中面临一个核心约束：模型的原生上下文窗口是有限且易失的。现有研究表明，即便上下文窗口被扩展，它仅提供会话内的召回能力，并不能自动实现跨会话的持久保留、共享与检索，因此不构成真正意义上的长期记忆（long-term memory, LTM）[1]。基于提示的 LLM 智能体受上下文窗口大小限制，无法回忆已见内容，也难以在少量演示之外持续学习 [2]。在静态检索增强生成（Retrieval-Augmented Generation, RAG）范式下，检索通常针对单一查询执行，缺乏面向跨会话可写状态的读写接口；而参数化知识既难以在推理时被精确更新，也难以携带个体经验与交互轨迹。作者在 MemGPT 中进一步指出，LLM 需要借助外部存储与类似操作系统的自主记忆管理，才能突破固定上下文窗口的约束 [3]。这些限制共同构成了长期任务引入外部可写记忆的基本动因。

为此，研究者已提出多种长期记忆实现方案。生成式智能体（Generative Agents）以自然语言记忆流记录智能体全部经验，通过相关性、新近性与重要性综合筛选，并引入反思机制将记忆综合为高层推断 [4]。MemGPT 将主上下文划分为只读系统指令、可写工作上下文与消息队列，外部上下文类比磁盘存储，记忆编辑与检索完全由 LLM 自主完成 [3]。RET-LLM 旨在提供通用读写记忆，支持跨任务知识存储与检索，且不修改 LLM 架构 [5]。ExpeL 通过自主收集经验并提取跨任务洞察实现学习与回忆 [2]。Mem0 与 A-Mem 则分别从生产级记忆操作与动态组织机制角度，尝试构建可扩展、可演化的记忆系统 [6, 7]。然而，作者指出当前系统多停留在基础存储与检索层面，即使引入图数据库，也可能因固定操作与预定 schema 而受限 [7]。同时，术语与边界的不统一增加了横向比较的困难；CoALA 框架从认知架构角度区分了程序性、语义与情景三类记忆，为理解智能体内部状态提供了概念参照 [8]。安全综述则将长期记忆界定为可写、跨会话的持久记忆，并提出涵盖写入、存储、检索、执行、共享与传播、遗忘与回滚的生命周期框架 [1]。

在上述背景下，本文关注长期任务中外部记忆机制的读写闭环及其对智能体行为的影响，而非参数化记忆更新，也不研究单查询检索式 RAG 的检索质量本身。围绕跨会话可写外部记忆，本文提出以下研究问题：

RQ1（定义与边界）：长期记忆包含哪些信息和机制？它与上下文历史、静态知识检索、参数知识有什么关系？

RQ2（组织与使用）：写入、组织和检索方法如何影响信息可用性、任务表现和成本？

RQ3（更新与遗忘）：如何处理信息变化、时间条件、冲突、过时记忆和必要的删除？

RQ4（可靠性）：错误摘要、错误反思或来源混淆如何进入记忆并影响后续决策？现有方法怎样发现和控制这些问题？

RQ5（评测）：基准和实验是否真正考察跨会话记忆、更新能力和长期任务表现？不同结果能否公平比较？

上述研究问题限定在跨会话可写的外部记忆范围之内。本文综合已有工作，但不将参数化记忆纳入讨论，也不对单查询检索式 RAG 的索引与排序算法作系统比较。对于跨系统、跨任务的可比较度量与结论，若素材未直接给出，本文仅作定性综合，并明确说明证据的适用条件与局限。

2 概念界定与综述方法

2.0.1 长期记忆的操作定义

在语言智能体（language agent）研究中，”长期记忆”（long-term memory）一词的使用并不统一。CoALA（Cognitive Architectures for Language Agents）框架将智能体记忆划分为程序性记忆（procedural memory）、语义记忆（semantic memory）与情景

记忆（episodic memory）三类，其中程序性记忆存储行为规则集，学习机制可修改行为规则 [8]。作者明确指出，新一代认知语言智能体虽用大语言模型管理内部状态，但术语不统一，难以在不同架构之间进行横向比较 [8]。这一概念划分源自 Soar 认知架构，CoALA 将其作为直接思想来源 [8]。

与上述认知架构视角不同，安全综述文献从记忆生命周期的角度给出了更具操作性的定义。作者称长期记忆为可写、跨会话持久记忆，具有持久性、状态性与传播性三个属性，并区分于更大的上下文窗口：后者仅提供会话内 recall，不自动跨会话保留、共享或检索 [1]。该文据此提出六阶段记忆生命周期框架，包括写入、存储、检索、执行、共享与传播、遗忘与回滚 [1]。

本文综合上述两种视角，将长期记忆的操作定义明确为：由智能体显式写入并跨会话持久化的信息状态，其生命周期涵盖写入、存储、检索、更新与遗忘等阶段。此定义将长期记忆与三类相关但不同的概念划清边界。第一，上下文历史（context history）与会话内工作记忆不属于长期记忆；更大的上下文窗口不构成持久记忆 [1]。第二，静态检索增强生成（retrieval-augmented generation，RAG）所依赖的外部知识库，若无智能体写入行为且不随交互演化，不在本文长期记忆范畴内；只有当检索语料被智能体主动写入或修改时，才进入记忆生命周期框架。第三，参数知识（parametric knowledge）内嵌于模型权重，不经过显式写入与检索步骤，亦不属于本文所界定的长期记忆。该边界论断基于作者对 MemGPT、MemoryBank、Mem0 等长期记忆实现的比较分析 [1]，但其攻击分类按写入阶段攻击者权限梯度组织，保留策略风险分析限于攻击场景下的 retention、decay、eviction 机制 [1]，对正常交互场景下记忆生命周期各阶段的系统覆盖仍属开放问题。

2.0.2 综述方法

检索阶段执行 104 次检索运行，覆盖 OpenAlex、Crossref 与 arXiv 三个学术数据源；其中 76 次成功、17 次失败，全部运行记录入档。检索截止日为 2026-10-17。命中去重后得到 691 项独立研究；版本归并策略将 arXiv DOI 与正式 DOI、预印本与会议版本关联至同一 work_id，避免同一研究因多版本而被重复计数。

筛选采用两阶段漏斗。第一阶段为题名与摘要初筛：691 项中 255 项纳入、42 项排除（以稳定理由码记录排除原因）、10 项待定。第二阶段为正文审读：确定 40 篇核心阅读池，按七层结构组织；其中 39 篇完成深度阅读，产出核心池证据 143 条（每条均含逐字摘录与页级定位，供后续章节引用核验；另有辅助池证据 203 条为批处理阶段产出、不进入正文引用链）。另有 215 项降为辅助池，不进入深读流程。

需要诚实说明本研究的方法局限。首先，检索虽覆盖三个数据源，但未能穷尽全部预印本平台与会议论文集，存在漏检风险。其次，版本归并依赖元数据中的 DOI 关联，对于缺少正式 DOI 或跨库关联断裂的研究，去重可能不完全。再次，题名摘要初筛以稳定理由码记录排除原因，但未进行双人独立标注，筛除决策的一致性未经正式检验。最后，证据提取虽要求逐字摘录与页级定位，但摘录边界由单一研究者裁定，他人复核

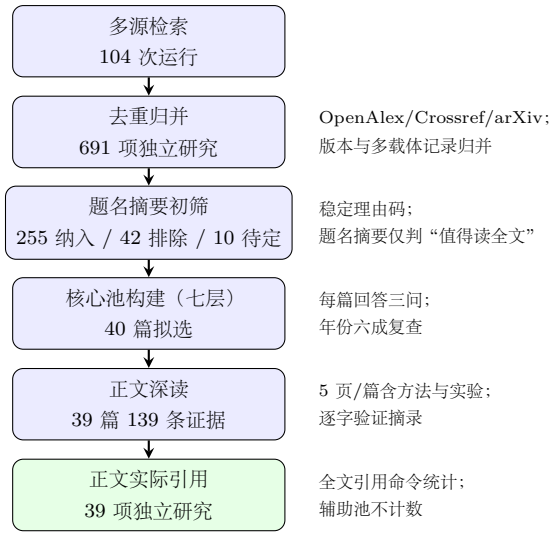


图 1: 文献筛选流程（真实统计，来自 `data/` 研究记录；计数单位为去重后独立研究 work_id，同一研究的预印本/正式版/演讲载体合并计数）。

尚不充分；本文在引用证据时尽量保留原文表述，并在综合判断处明确区分作者声称与本文推断，但上述局限仍在客观上限制了综述结论的可复现强度。

3 研究脉络与方法分类

智能体长期记忆系统的研究可按机制演进划分为四个阶段：从奠基性的记忆流与三因子检索，到面向固定上下文窗口的虚拟上下文管理，再到结构化记忆组织，最后走向效率导向的固化与压缩策略。这一脉络并非线性替代，而是问题重心与设计约束的持续迁移。

3.0.1 记忆流与三因子检索

Park 等人在 Smallville 沙盒中提出了生成式智能体的奠基范式，以自然语言记忆流记录智能体全部经验，并在检索时综合相关性（recency）、新近性（importance）与重要性三个因子筛选记忆，同时引入反思模块将记忆综合为高层推断 [4]。作者通过消融实验称观察、规划、反思每个组件都对行为可信度有关键贡献 [4]。这一工作确立了“写入—检索—综合”的基本框架，但其记忆组织本质上是扁平的相似度检索，且实验环境限于 Smallville 沙盒 [4]。后续研究者指出，这类基于相似度检索的系统在写入阶段不进行信息蒸馏，读取时完全依赖查询驱动检索，难以处理跨文档矛盾与时间性信息 [9]。

3.0.2 上下文工程与虚拟记忆管理

面对 LLM 固定上下文窗口的限制，MemGPT 将主上下文划分为只读系统指令、可写工作上下文与 FIFO 消息队列，外部上下文类比磁盘存储，仅通过函数调用进行读

写 [3]。作者称记忆编辑与检索完全由 LLM 自主决定，队列驱逐策略可释放约 50% 上下文窗口空间并生成递归摘要 [3]。然而，其工作上下文仍为固定大小的非结构化文本块，外部记忆必须显式移入主上下文才能参与推理 [3]。ExpeL 同样针对上下文窗口限制，通过自主经验收集与自然语言知识提取实现跨任务学习，在推理时召回洞察与过去经验 [2]。作者明确指出，基于提示的 LLM 智能体受上下文窗口大小限制，无法回忆已见内容 [2]。这一阶段的共性问题是：记忆仍以非结构化文本为主，检索粒度受限于上下文窗口的物理边界。

3.0.3 结构化组织：从图到分层与多类型

为突破基础存储与检索的局限，研究者开始引入图结构与动态组织机制。A-Mem 将新记忆构建为包含上下文描述、关键词、标签等属性的笔记，并在整合新记忆时更新旧记忆的表示，实现记忆演化 [7]。作者指出，当前系统如 Mem0 只提供基础存储与检索，即使引入图数据库也因固定操作而受限 [7]。Zep 采用时序知识图谱架构，区分情节子图、语义实体子图与社区子图，并通过双时序模型区分现实有效区间与系统事务区间，使旧边在矛盾时被置为失效但保留在图中 [10]。作者称在 DMR 基准上 Zep 表现优于 MemGPT（94.8% vs 93.4%），在 LongMemEval 上准确率最高提升 18.5%，延迟降低 90%[10]。

Mem++ 则选择了另一条路径：写入时完整保存带日期与作者的每个文档，不蒸馏、不覆盖；读取时按问题时间上界筛选文档并融合词汇与语义排序 [9]。作者称这种非破坏性组织在 OrgMemBench 上超越最强基线 8.0–13.1 分，在 gpt-4.1-mini 下比 RAG 高 2.6 分 [9]。与传统压缩式系统（如 Mem0）覆盖式写入形成对比，Mem++ 保留了冲突陈述的可回答性 [9]。Synapse 进一步提出扩散激活机制，融合情景与语义记忆以克服“上下文隔离”问题，在 LoCoMo 上加权平均 F1 达 40.5，超过 A-Mem（33.3）、Zep（39.7）与 AriGraph（33.7）[11]。HiGMem 则采用分层图记忆与 LLM 引导检索，在 LoCoMo10 上将平均检索轮数从 A-Mem 的 99.84 降至 8.09，对抗性 F1 从 0.54 提升至 0.78[12]。

与此同时，MIRIX 提出六种结构化记忆类型（Core、Episodic、Semantic、Procedural、Resource Memory 与 Knowledge Vault），由多智能体框架动态协调更新与检索 [13]。作者称在 ScreenshotVQA 上相对 RAG 基线准确率提升 35%、存储降低 99.9%，在 LOCOMO 上达到 85.4% SOTA[13]。SodaMem 则将证据锚定与时间图结构结合，在检测到同一 subject–predicate 槽位时写入新事实并主动失效旧事实，读取时以软时间窗口加分而非硬过滤 [14]。作者称在 LongMemEval-S 上 store-of-record 配置达到 92.8% 准确率（464/500）[14]。

3.0.4 效率与固化策略

结构化记忆虽然提升了检索质量，却带来了记忆构建的 token 成本问题。RecMem 提出基于复现的记忆固化，作者称在 LoCoMo 基准上记忆构建 token 消耗比基线最多降低 7.8 倍 [15]。RecMem 论文报告其记忆构建消耗约 193.2K tokens，而 MemoryOS 约

1520.8K、Mem0 约 1459.9K[15]。作者称既有系统普遍采用急切记忆固化，RecMem 以差异化组织方式降低固化开销 [15]。Mem0 本身从生产级视角出发，作者称在 LOCOMO 基准上相比 OpenAI 在 LLM-as-a-Judge 指标上实现 26% 相对提升，但结合图记忆的整体得分仅比基础版高约 2%[6]，提示图结构在特定评测条件下增益有限 [6]。

总体而言，早期工作聚焦于“如何记住”，以记忆流和检索因子奠定基础；上下文工程阶段回应“如何突破窗口”，以虚拟上下文和自主编辑缓解物理限制；结构化组织阶段转向“如何组织与演化”，以图结构、分层表示与多类型记忆管理提升信息的可用性，但其增益高度依赖任务与检索设置（见第 4 节与第 5 节）；近期前沿工作则进一步追问“何时该遗忘”与“是否可信”——遗忘治理、来源追踪与错误传播控制成为新的焦点（详见后续章节）。

表 2: 核心池 40 项研究六维分类（模型分类，待人工复核；依据 = 阅读卡证据）

工作	年	角色	内容	表示	生命周期	时间	信任	评测
W0001	2023	奠基范式	事件情景	原始片段	全生命周期	时间戳	无	长期任务成功率
W0002	2023	虚拟上下文管	混合	分层	全生命周期	时间戳	无	无
W0004	2023	语言化经验	程序性经验	摘要卡片	写入	无	无	无
W0680	2023	读写式记忆	事实	结构化记录	检索	无	无	召回精度
W0003	2024	遗忘引入	事实	混合	遗忘	时间戳	无	长期任务成功率
W0618	2024	经验池	程序性经验	摘要卡片	写入	无	无	无
W0681	2025	动态组织	事件情景	结构化记录	全生命周期	无	无	更新正确性
W0682	2025	生产级记忆操	混合	混合	全生命周期	无	无	召回精度
W0105	2025	多类型记忆系	混合	混合	全生命周期	无	无	召回精度
W0684	2025	时间知识图谱	事件情景	图	全生命周期	有效区间	无	召回精度
W0028	2026	非破坏性组织	事实	原始片段	全生命周期	时间戳	来源标注	召回精度

工作	年	角色	内容	表示	生命周期	时间	信任	评测
W0030	2026	分层图记忆	混合	图	检索	无	无	召回精度
W0099	2026	情景-语义分	混合	分层	检索	时间推理	无	召回精度
W0107	2026	递归巩固	事件情景	混合	写入	无	无	无
W0222	2026	证据锚定时间	事实	图	全生命周期	有效区间	无	更新正确性
W0011	2026	偏好演变更新	任务状态	向量库	更新	无	无	无
W0012	2026	检索驱动再巩	混合	图	更新	无	无	无
W0034	2026	图记忆选择性	事实	图	遗忘	时间戳	无	召回精度
W0077	2026	版本规范化	事实	结构化记录	写入	无	无	无
W0178	2026	预算策展遗忘	混合	向量库	遗忘	无	信任分数	攻击鲁棒性
W0180	2026	存储/使用分	事实	结构化记录	遗忘	版本链	无	更新正确性
W0199	2026	遗忘治理原语	任务状态	混合	更新	时间戳	信任分数	长期任务成功率
W0005	2024	超长期对话 Q	事件情景	混合	检索	时间戳	无	召回精度
W0006	2024	五能力维度	事件情景	混合	检索	时间推理	无	召回精度
W0691	2025	综合记忆评测	混合	混合	全生命周期	无	无	无
W0031	2026	成本感知评测	混合	混合	全生命周期	无	无	成本
W0171	2026	召回 vs 遗忘	事件情景	混合	检索	时间戳	无	召回精度
W0379	2026	多模态评测	事件情景	混合	全生命周期	无	无	召回精度
W0434	2026	记忆构建方法	混合	混合	写入	无	无	下游问答
W0261	2025	记忆幻觉评测	混合	混合	更新	无	无	召回精度

工作	年	角色	内容	表示	生命周期	时间	信任	评测
W0010	2026	来源感知	事实	结构化记录	检索	无	来源标注	召回精度
W0207	2026	压缩信息损失	混合	混合	写入	无	无	成本
W0688	2026	错误传播	事实	混合	更新	无	验证过滤	召回精度
W0690	2026	检索可采纳性	混合	混合	检索	无	验证过滤	召回精度
W0076	2026	攻防综合	事实	向量库	检索	时间戳	信任分数	攻击鲁棒性
W0312	2026	防御成本	事件情景	向量库	检索	无	验证过滤	良性成本
W0319	2026	选择性绕过后	混合	混合	写入	无	无	攻击鲁棒性
W0140	2023	概念框架	程序性经验	结构化记录	更新	无	无	无
W0056	2025	记忆机制综述	混合	混合	全生命周期	无	无	无
W0039	2026	安全综述	混合	混合	全生命周期	无	无	攻击鲁棒性

4 记忆更新与可靠性

记忆系统的长期可靠性首先取决于更新与遗忘机制能否在不损害有用信息的前提下淘汰过时或冗余内容。现有工作从选择性遗忘、治理原语、存储/使用分离、再巩固、版本规范化与偏好更新等不同路径探索这一问题。

图结构记忆中的选择性遗忘是代表性做法。W0034 在 LongMemEval 基准上以提取式流水线评测图结构记忆（27021 个节点，候选生成预算为 5 个检索根），其选择性遗忘模块按 recency、访问频率、度中心性和 age 加权得分剪枝低分节点。作者报告，一次应用遗忘移除 9.8% 节点与 9.5% 存储字节，token F1 变化 +0.001（95% CI [-0.015, +0.016]），judged correctness 下降 1.6 点；同时图结构记忆的 token F1 为 0.417，低于扁平向量基线的 0.468（配对 bootstrap Δ=-0.050）[16]。这说明在该设定下，图结构与剪枝策略并未带来召回优势，遗忘更多是成本控制手段而非性能提升手段。

与基于启发式得分的剪枝不同，W0199 提出 Memory Worth 作为遗忘治理的在线原语：系统在写入时记录记忆是否属于当前集合，在读取时通过任务成败反馈持续估计条件成功概率。作者称在合成环境（真实效用已知、20 个独立种子、10000 回合）中，Memory Worth 与真实效用的斯皮尔曼秩相关达到 $\rho = 0.89 \pm 0.02$，而从不更新的系统

为 $\rho = 0.00$；在真实文本微实验（all-MiniLM-L6-v2 嵌入检索、3000 回合）中，过时记忆 MW=0.17 低于低价值阈值，专家记忆 MW=0.77。作者特别说明该度量捕获的是关联而非因果，应视为最小操作原语 [17]。

W0178 则把遗忘与信任、防投毒统一在同一预算策展框架下。CURATOR 以“净值/字节”单一评分管理经验记忆的保留、共享与信任，净值含价值项与危害项（含来源项）。作者称在 Qwen2.5-3B、Qwen2.5-7B、Phi-3.5-mini 上，仅按价值筛选或全量保留均使注入攻击成功率保持很高，而加入来源项的净值得分可将 ASR 降至零 [18]。这一结果表明，遗忘决策不能只看信息价值，还需显式建模来源可信度。

关于“该遗忘什么”，W0180 主张将存储与使用分离：归档保留源观察，查询条件视图决定哪些证据被用于回答，遗忘因而是查询局部的——事实可以继续存储但在特定答案中被抑制使用。作者在五个任务套件、四个语言模型骨干上评测 RD-Forget，报告在事实整合任务上相对更强基线的提升为 11 到 26 个百分点不等，且无遗忘配置与查询无条件配置在消融中得分最低 [19]。

W0012 提出检索驱动的再巩固（REALM）：将插入、合并与遗忘统一为单一整合阶段，把遗忘视为冗余处理。作者称 REALM 在 LoCoMo 上平均准确率 75.97%、在 LongMemEval 上 65.11%，分别比最强基线高 7.17 和 1.31 个百分点 [20]。这一思路与分离式流水线形成鲜明对比，但证据未详述冲突与信息变化的具体处理。

版本规范化处理的是跨模型记忆漂移问题。W0077 以“解释熵”刻画记忆对象被不同模型赋予不同解读的程度，主张将消歧从检索时前置到写入时。作者在 n=176 合成记忆对象、三个下游模型家族的配对准随机测试中发现，全规范化记忆相对原始记忆在情感一致性上有未校正的显著改善（+0.050，95% bootstrap CI [0.013, 0.086]，配对 t 检验 p=0.0），但多重比较校正后不再显著；事实漂移在任何校正水平下均不显著。作者明确将这些结果定性为探索性而非确认性 [21]。本文综合认为，版本规范化在概念上切中跨模型部署的痛点，但其经验证据强度尚不足以支撑强结论。

偏好更新方面，W0011 批评 MemGPT、MemoryBank、A-MEM、SCM、MemInsight 等系统默认用户行为静态、缺乏偏好漂移自适应更新，并提出融合短期滑动窗口与长期指数移动平均的偏好表征。作者称 PAMU 在 $\lambda \in [0.4, 0.7]$ 与 $\beta \in [0.8, 0.95]$ 范围内性能稳定 [22]。这提示偏好记忆需要同时追踪波动与趋势，但该结论的量化评测细节在所给证据中未展开。

4.1 非恶意可靠性

即使没有恶意攻击，记忆系统在抽取、更新、检索与压缩各环节都可能因信息失真而不可靠。

错误传播是流水线式智能体系统的突出风险。W0688 在 4 智能体 LangGraph 流水线（Researcher→Analyst→Writer→Reviewer）上，以 FinanceBench 数据、346 条注入幻觉、gpt-4o-mini 智能体与 gpt-4o 评判进行评测。作者称幻觉检测率从 Stage 1 的 72.0% 单调下降到 Stage 4 的 50.9%；边界门控使幻觉生存率从 58.4% 降至 16.2%，而

末端检查仅改善 2.3 个百分点，作者称该改善在统计上可忽略 [23]。这一对比说明，在错误产生的边界处设防比在输出末端检查更有效。

记忆幻觉可能在多个操作环节累积。W0261 提出操作级评测 HaluMem，区分记忆抽取、记忆更新与记忆问答三个任务。作者称现有记忆系统倾向于在抽取和更新阶段产生并累积幻觉，随后向问答阶段传播错误；并指出 LoCoMo、LongMemEval、PrefEval、PersonaMem 等基准采用端到端黑盒评估，难以定位幻觉发生的具体环节 [24]。本文综合认为，操作级诊断对可靠性的归因分析不可或缺，但该结论的经验基础限于 HaluMem-Medium 与 HaluMem-Long 数据集的评测范围。

检索环节的另一类失败是“证据不具可采纳性”。W0690 指出，现有评测只关注召回和最终答案正确性，无法识别检索到正确内容但因语境不匹配而不应被使用的失败模式。作者在 RHELM 与 MemOps 共 3767 个查询的 top-20 设置中报告，采用发布元数据参照后，Top-20 anchor recall 从 0.432 提升到 0.533，80% recall feasibility 从 0.237 提升到 0.311，exact similarity evaluations 下降 98.3%；在冻结 72 案例开发诊断中，仅文本验证器在 1% 必需锚点误拒上限内无法检测违规 [25]。这表明检索可采纳性需要超出语义相似度的验证信号。

来源追踪是抑制错误传播与幻觉的通用手段。W0010 提出来源感知记忆系统，存储对话事实的同时记录来源与置信度，并在读取时施加引用锁纪律：答案只能引用已打开的证据，无法组成引用集则弃权。作者报告在 LongMemEval 上达 95.60%（较此前最强系统 +0.73 分），在 LoCoMo 上达 93.60%（+1.10 分）；在八个骨干 LLM 的受控实验中，准确率仅差 3.4 分而单查询成本差约 30 倍，作者称能以约 20 倍低成本达到接近 SOTA 质量 [26]。该工作的证据强度相对较高，覆盖两个基准与多骨干模型。

从信息论视角看，所有紧凑记忆形式——KV 缓存、gist 向量、循环状态与智能体笔记——共享同一 Fano 下界约束。W0207 指出，查询无关压缩的有效每查询预算被查询分布熵 H(Q) 削减，快照式方法在查询分布变化时性能塌陷；作者还指出现有评测仅仔细测量单轮长上下文压缩，智能体实际执行的重复压缩几乎未被测量 [27]。这为理解记忆压缩失真提供了一个统一的理论参照，但其 COMPACT-Bench 的实证数据在给定证据中未提供。

4.2 恶意攻击与防御及其代价

当记忆系统暴露于对抗性输入时，选择性提取与改写机制本身可能被利用。W0319 提出的 MemPoison 针对具有选择性提取与改写两阶段的 LLM 智能体记忆流水线，攻击者仅通过交互注入、无直接记忆写权限，但可借助本地白盒代理嵌入模型优化触发器。作者称 MemPoison 跨多智能体领域与记忆机制的攻击成功率最高可达 0.95，优于静态 RAG 或直接写库类基线 [28]。这揭示了一个深层矛盾：为可靠性设计的筛选流水线反而为绕过滤创造了新攻击面。

信任评分能否有效阻止投毒，取决于评分是否能区分安全内容与模型确信的内容。W0076 在写入时采用复合信任分数门控，在检索时进行含时间衰减的信任过滤与排序。

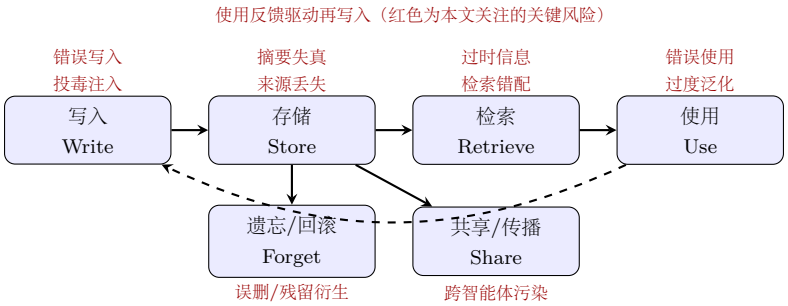


图 2: 记忆生命周期与关键风险示意（概念图，依据综述文献的生命周期框架归纳 [1]；红色标注各阶段风险，详见第 ?? 节）。

其记忆净化实验采用 MIMIC-III 数据集、101 条投毒查询和四个 few-shot 示例，并分别以 GPT-4o-mini-class 与 Gemini-2.0-Flash 同时承担主智能体和守卫智能体。GPT-4o-mini 配置拒绝全部 23 条候选记忆，长期记忆在该次运行中保持为空；Gemini 配置接受 82 条记忆，其中 54 条被确认为恶意内容，且被接受条目的信任分数均为 1.0，因此在阈值为 0.5 的检索过滤模拟中无一被滤除 [29]。上述结果提示，在这些配置下，零投毒泄漏可能伴随无法保留信息的代价，而高信任分数也可能反映模型对恶意内容的错误确信；防御评价必须同时检查记忆保留情况与实际内容安全性。

防御评估还需考虑良性用例的效用代价。W0312 在完全良性的 LoCoMo 对话流量上，保持记忆后端、检索配置与判断器一致，以五段对话、每种条件三次重复测量读取端 reranker 防御的副作用。作者报告核心准确率下降 4.4 个百分点（95% bootstrap CI $[-9.0, -0.05]$；McNemar $p = 0.064$），良性条目的误隔离率为 33.6%，单个对话最多出现 106 次误隔离，令牌开销为 2.7%[30]。bootstrap 区间上界仅略低于零，而 McNemar 检验未达到 0.05 阈值，作者因此谨慎地将准确率变化解释为处于统计分辨率边缘的结果，并更强调误隔离所揭示的机制性代价 [30]。本文据此主张，防御评价应在可比配置下同时报告攻击抑制效果、良性准确率、误隔离率与资源开销；上述良性流量实验本身不能确定防御在攻击场景中的收益，也不能与其他论文的攻击实验直接组成方法优劣排序。

5 评测与比较

长期记忆评测基准的演化呈现出从“长度优先”到“能力维度优先”的清晰轨迹。LoCoMo（Long-Term Conversational Memory）将评测对象推进至超长期对话记忆，其平均会话长度是此前 MSC 的 16 倍，对话轮数多出 10 倍以上 [31]。然而，长度扩展只是表层挑战：LoCoMo 中 94% 的评估问题仅需不超过 2 个此前会话的证据即可回答，说明该基准本质上仍倾向于浅层检索而非深层记忆整合 [32]。LongMemEval 在此基础上提出五能力框架，将长期交互记忆系统化为信息提取、多会话推理、时间推理、知识更新与弃答（refusal）五类核心能力 [33]。该基准的另一贡献在于将记忆内容区分为用户信息与助手信息两个来源，并明确批评既有基准缺乏对“助手提供过的信息”的回忆评测

[33]。

随后的工作在多维度上扩展了评测空间。Memora 针对召回与遗忘的对立关系，将时间有效性纳入评测：答案正确性须避免使用已失效记忆，以此检验系统对记忆变更的敏感度 [32]。Mem-Gallery 则指出此前基准"要么仅限文本、要么仅在单会话局部上下文内评估多模态理解"的根本缺口，引入跨会话多模态记忆评测 [34]。MemBench 从记忆层级出发，区分事实记忆（fact memory）与反思记忆（reflective memory），并设置参与与观察两种交互场景，补充了先前基准偏重事实记忆、单一场景的不足 [35]。成本感知评测则从工程实用视角提出问题：记忆何时真正有帮助？在依赖任务上，长期记忆可将成功率从无记忆基线的 0.00 提升至 0.55–1.00；但在更新事实场景中，嵌入检索的成功率仅为 0.30–0.95，而更新即写（update-on-write）存储保持在 0.70–1.00[36]。

从比较维度看，各基准在任务类型、会话跨度、信息变化与指标设计上差异显著。LoCoMo 聚焦超长对话问答，以约 16K tokens、588.2 turns、27.2 sessions 的规模设置长跨度条件 [31]；LongMemEval 在 500 个手工问题、可扩展至约 1.5M tokens 的设置下覆盖五类能力 [33]；Memora 引入 Weekly/Monthly/Quarterly 的时间增量，专门施压于记忆整合与变更 [32]；Mem-Gallery 将任务扩展至跨会话多模态场景 [34]；MemBench 在事实与反思两个层级上施加对比压力 [35]。信息变化维度上，多数基准假设静态记忆，而 Memora 与 LongMemEval 明确引入知识更新与失效记忆处理 [32, 33]，W0031 的更新即写机制进一步将"信息写入时机"作为影响可靠性的核心变量 [36]。

公平比较的困难根植于多个维度。其一，模型与预算差异：成本感知评测揭示，不同记忆机制的总成本与模型选择紧密耦合，仅 23,440 个得分 episode 即需 $42.57，嵌入检索与事实库方案在同一模型网格下表现分化 [36]。其二，检索配置差异：同一嵌入检索机制在更新事实场景中的成功率波动达 0.30–0.95，最大种子差距为 0.45，说明实现细节与初始化策略足以改变结论 [36]。其三，评测目标本身的分歧：LoCoMo 偏向会话跨度压力，LongMemEval 侧重五能力覆盖，Memora 强调失效记忆规避，Mem-Gallery 关注多模态瓶颈 [31–34]。作者依据 Mem-Gallery 的结果称，记忆机制在推理与知识管理上存在局限，且存在效率瓶颈 [34]；W0031 进一步指出，代理仅在 55% 的时间内对正确检索值采取行动，忽略率高达 0.45–0.53，表明"检索到"不等于"用得上"[36]。这些因素使得跨基准的横向比较缺乏统一的公平基础——不同评测在"什么算记住"与"什么算用好"上尚未达成共识。

记忆构建质量的评估还需区分方法与基准。MemBuilder 是训练型长期记忆构建方法，在 LongMemEval、LoCoMo 与 PerLTQA 三个已有基准上评测；其主要对照固定 Claude 4.5 Sonnet 为回答模型、GPT-4.1 为评判，以隔离不同记忆构建策略对下游问答表现的影响 [37]。该工作提供的是构建方法及其评估设计，独立评测基准的比较见表3。

表 3: 评测基准比较（依据阅读卡证据整理，待人工复核；完整定位见证据库）

基准	年份	评测设置	主要发现（摘要）
W0005	2024	使用 LOCOMO 基准，包含约 16K tokens、588.2 turns、27…	作者称即使使用长上下文 LLM 或 RAG，模型在非常长期对话记忆上的表现仍远落后于人类…
W0006	2024	基准为 LongMemEval，包含 500 个手工问题…	作者称此前长期记忆基准（如 LoCoMo）未评测回忆助手提供的信息或对更新后的用户信息进行推理…
W0031	2026	基于 MERIT 基准，共评测 23,440 个得分 episode…	总体：长期记忆将依赖任务成功率从无记忆的 0.00 提升至 0.55 – 1.00（pdf:p1 Abstract…
W0171	2026	Memora 基准包含多会话对话、基于记忆的评估问题和以每个 persona 显式记…	作者称 Memora 在记忆整合和记忆变更要求上显著高于已有基准 () …
W0379	2026	任务为跨会话多模态对话记忆评测；数据为 Mem-Gallery 数据集…	作者称基于 13 个记忆机制评测得出四项发现：(1) 显式保存视觉信息有益；(2) 记忆组织是必要的…
W0691	2025	提出 MemBench 基准，包含事实记忆与反思记忆两个层级…	作者称 MemBench 的核心设计特征为同时覆盖记忆的两个层级与两种交互场景…

6 挑战与研究方向

现有长期记忆评测体系对“更新”环节的覆盖明显薄弱。LongMemEval 虽然将知识更新列为五项核心能力之一，要求模型对更新后的用户信息进行推理，但其评测仍以最终问答正确性为主 [33]。Memora 进一步指出，既有基准对记忆整合与变更的要求不足：作者称 LoCoMo 中 94% 的评估问题只需不超过 2 个此前会话的证据，LongMemEval 中该比例为 85%[32]。这意味着多数题目可以通过浅层检索解决，难以暴露更新冲突、过期信息抑制等深层问题。HaluMem 的作者也批评既有基准（LoCoMo、LongMemEval、PrefEval、PersonaMem）采用端到端黑盒评测，只能通过最终任务表现间接观察记忆系统行为，无法定位幻觉发生在抽取、更新还是检索阶段 [24]。

从更新机制本身看，若干工作报告了初步但零散的证据。W0034 的选择性遗忘在 LongMemEval 上仅应用一次剪枝，移除 9.8% 节点和 9.5% 存储字节，token F1 变化为 +0.001（95% CI $[-0.015, +0.016]$），而 judged correctness 下降 1.6 点 [16]。该结果来自提取式流水线与 27021 节点图的单次剪枝，既未考察多次、连续更新条件下的累积效果，也未说明 correctness 下降的机制。W0180 在事实整合任务上报告 RD-Forget 相对更强基线提升 11 到 26 个百分点（四个骨干模型），但其评测集中在查询条件下的答

案效用，未分离“更新正确性”本身 [19]。W0199 的 Memory Worth 估计在合成环境中 10,000 回合后与真实效用的斯皮尔曼秩相关达 $\rho = 0.89 \pm 0.02$（20 个种子），但作者明确称该度量反映关联而非因果，且理论收敛依赖平稳检索机制与最小探索条件 [17]。这些结果均未形成对“更新是否正确发生”的标准化、可比较评测。

本文综合认为：更新正确性评测的缺口有三层。其一，现有基准对知识更新的触发、冲突消解和过期抑制缺乏操作级标注，端到端准确率无法归因。其二，更新性能的报告分散在合成环境、单一基准或特定框架下，条件不可比。其三，选择性遗忘或再巩固等更新算子本身的效果证据很弱甚至为负，但缺乏统一的更新质量度量来判定这是方法缺陷还是评测不足。

6.1 错误传播的定量刻画缺失

多智能体流水线中的错误传播已有初步定量证据。W0688 在 4 智能体 LangGraph 流水线（Researcher→Analyst→Writer→Reviewer）上报告：幻觉检测率从 Stage 1 的 72.0% 单调下降到 Stage 4 的 50.9%；边界门控使生存率从 58.4% 降至 16.2%，而末端检查仅改善 2.3 个百分点，作者称该改善在统计上可忽略 [23]。该实验限于 FinanceBench 数据集与 gpt-4o-mini/gemini-2.5-flash 组合。这说明末端验证并不能有效阻断已经跨阶段累积的错误。

然而，记忆系统内部的错误传播远未被定量刻画。W0261 报告现有记忆系统倾向于在抽取和更新阶段产生并累积幻觉，随后向问答阶段传播，但未给出各阶段间转移概率或累积率的数值 [24]。W0031 在 MERIT 基准上发现嵌入检索在更新事实场景下成功率波动于 0.30–0.95，最大种子差距 0.45，而更新即写的结构化事实库和 LLM 摘要保持 0.70–1.00；作者还报告代理仅在 55% 的时间对正确检索值采取行动，忽略率为 0.45–0.53[36]。这些数据揭示了“检索正确但行动错误”的中间失败模式，但未建模从写入到读取再到决策的逐步衰减。

W0207 从速率–失真角度指出，智能体实际执行的重复压缩几乎未被测量，现有评测仅覆盖单轮长上下文压缩 [27]。这一观察与错误传播问题同构：单轮压缩误差与多轮累积误差是不同量级的问题，但后者缺乏基准。W0690 进一步说明，现有长期记忆评测只关注召回和最终答案正确性，无法识别“证据不具可采纳性”的失败模式 [25]。本文判断，错误传播的定量刻画缺失表现为三个层面：跨智能体阶段、跨记忆操作阶段、跨时间轮次，三者均缺乏统一的传播模型与测量指标。

6.2 成本与收益报告的不统一

成本感知评测的证据高度碎片化，难以横向比较。W0031 在 MERIT 基准上评测 23,440 个得分 episode，总成本 $42.57，并报告长期记忆将依赖任务成功率从无记忆的 0.00 提升至 0.55–1.00[36]。该实验使用 gpt-4.1-mini、GPT-4.1、Claude Haiku 4.5，记忆侧固定。这一“总成本 $42.57”的数字仅对该特定评测设置有意义，无法外推。W0010

在八个骨干模型上报告单查询成本差约 30 倍，并称能以 20 倍低成本达到接近 SOTA 质量，但其成本口径未在证据中细化 [26]。

另一方面，多数更新机制工作完全不报告成本。W0034、W0180、W0199、W0012 均聚焦准确率或 F1 指标，未提供记忆写入、剪枝、再巩固的算力或延迟开销 [16, 17, 19, 20]。W0434 的作者指出提示型记忆框架（Mem0、MIRIX、MemGPT）缺乏下游反馈且依赖强模型，而训练型方法（Memory-R1、Mem-α）存在轨迹级稀疏奖励瓶颈 [37]；这间接说明成本问题与学习信号问题是耦合的。W0379 在多模态记忆评测中报告存在效率瓶颈，但未给出统一的成本度量 [34]。

本文综合认为，成本与收益报告不统一的根源在于：缺少一个跨框架的成本轴。W0207 提出 COMPACT-Bench 旨在“在同一预算轴上统合所有层”，其动机正是现有评测缺乏统一的资源预算维度 [27]。若将记忆写入、存储、检索、更新各阶段的算力、延迟、存储字节纳入同一预算轴，并与任务收益联合报告，才可能形成有意义的比较。当前文献中“提升 X 个百分点”的收益声明与“总成本 $42.57”的孤立成本数字之间没有可通约的桥梁。

6.3 防御与治理的负外部性

遗忘与过滤机制在抑制错误或攻击的同时，可能损害合法记忆的可用性，这一负外部性在现有工作中已被局部观察到但未被系统量化。W0178 报告：仅按价值筛选或全量保留均使注入攻击成功率保持很高，而加入来源项的净值得分可将 ASR 降至零；该实验使用 Qwen2.5-3B、Qwen2.5-7B、Phi-3.5-mini 模型 [18]。然而，“将 ASR 降至零”是否伴随合法经验的误删或信任度下降，证据未报告。W0034 的选择性遗忘在移除 9.8% 节点的同时，judged correctness 下降 1.6 点 [16]，这是负外部性的直接信号，但作者未进一步分解哪类合法信息被误删。

W0690 的诊断更尖锐：在冻结 72 案例开发诊断中，仅文本验证器在 1% 必需锚点误拒上限内无法检测违规，而发布元数据参照能保留必需证据 [25]。这说明防御机制若过度依赖单一信号，可能在过滤违规的同时误拒合法证据。W0077 的全规范化记忆相对原始记忆在情感一致性上有未校正的显著改善（$+0.050$，95% bootstrap CI $[0.013, 0.086]$），但经多重比较校正后不再显著；事实漂移在任何校正水平下均不显著 [21]。作者将结果定性为探索性而非确认性。该结果提示：以规范化手段追求一致性，可能并未带来事实层面的收益，却引入了额外的写入约束。

本文判断，防御的负外部性尚未成为评测体系的正式维度。现有工作衡量 ASR、检测率或一致性，却极少报告“合法信息误拒率”“可用性损失”或“置信度误标”等反向指标。W0031 引入过期记忆导致的“自信错误行动”和忽略率作为失败模式 [36]，这是一个有价值的开端，但尚未推广到遗忘与过滤机制的研究中。负外部性的量化需要与收益指标在同一实验设置下联合报告，否则“ASR 降至零”之类的结论无法说明治理的实际代价。

7 结论

现有长期记忆系统的基础机制可归纳为三条技术脉络。第一条是以生成式智能体架构为代表的“记忆流 + 检索 + 反思”范式，通过自然语言记录经验，并在检索时综合相关性、新近性与重要性，再以反思模块生成高层推断 [4]。第二条是虚拟上下文管理路线，以 MemGPT 为代表，将主上下文划分为只读系统指令、可写工作上下文与 FIFO 消息队列，并借助函数调用实现对外部上下文的自主读写与驱逐 [3]。第三条是读写分离与经验提取路线：RET-LLM 通过微调生成记忆 API 调用，在不修改 LLM 架构的前提下实现显式存储与检索 [5]；ExpeL 通过自主收集经验并提取跨任务洞察，将回忆对象从原始经验扩展为自然语言知识 [2]。此外，MemoryBank 引入艾宾浩斯遗忘曲线启发的记忆更新机制，以记忆强度衰减模拟人类记忆的动态性 [38]；Reflexion 则以语言化自我反思构成情景经验记忆，作者报告其在 HumanEval 编码基准上以自反策略达到 91% pass@1[39]。综合来看，基础系统层已形成“写入—存储—检索—更新”的通用骨架，但在写入时机、记忆粒度和更新策略上仍缺乏统一约定 [2–5]。

7.1 RQ1：长期记忆与相关概念的边界是什么?

本文的操作定义将长期记忆界定为：由智能体显式写入并跨会话持久化的信息状态。这一边界排除了三类相关但不同的机制：上下文扩展仅提供会话内召回，不构成跨会话的持久写入 [1]；静态检索增强的外部知识库若无智能体写入行为且不随交互演化，不进入记忆生命周期 [1]；参数化知识在推理时无法被精确更新，也难以携带个体交互轨迹 [2, 3]。据此，综述覆盖的工作以” 写入—存储—检索—使用—更新” 的显式闭环为共同特征，而机制形态（记忆流、图结构、分层摘要、经验规则）与记忆类型（事实、事件、任务状态、程序性经验）构成设计空间的两条主轴 [1, 8]。

7.2 RQ2：组织与检索机制如何影响记忆系统的性能?

组织与检索机制构成了长期记忆系统性能分化的关键因素。时间知识图谱类系统（如 Zep）通过情节子图、语义实体子图与社区子图三层结构组织信息，并引入图感知重排器以提升检索质量 [10]。Mem++ 采用非破坏性组织策略，在写入时完整保存带日期与作者的文档，读取时按问题时间上界筛选，并在冲突场景中保留版本而非覆盖 [9]。分层图记忆系统 HiGMem 则通过 LLM 引导的证据集裁剪，在 LoCoMo10 基准上将平均检索轮数从 A-Mem 的 99.84 降至 8.09，同时取得更高精确率与相近召回率 [12]。扩散激活机制（Synapse）通过融合情景与语义记忆，在 LoCoMo 上取得加权平均 F1 40.5，超过 Zep 的 39.7 与 AriGraph 的 33.7[11]。然而，组织复杂性的增益并非线性：Mem0 结合图记忆的整体得分仅比基础版高约 2%[6]；一项图结构与扁平向量基线的对比研究显示，图结构记忆的 token F1 为 0.417，低于扁平向量基线的 0.468[16]。这表明，在特定评测条件下，组织机制的优势高度依赖于任务与检索设置，不能简单假定结构化组织

必然优于扁平存储 [6, 16]。

7.3 RQ3：更新与遗忘机制如何影响长期一致性?

更新与遗忘机制对长期一致性具有双重作用。在正向更新方面，检索驱动再巩固框架 REALM 将插入、合并与遗忘统一为单一整合阶段，在 LoCoMo 上平均准确率达 75.97%，比最强基线高 7.17 个百分点 [20]。SodaMem 通过 supersession 机制在新事实写入时主动失效旧事实，并以软时间窗口而非硬过滤处理时序查询 [14]。在遗忘治理方面，Memory Worth 估计在 10,000 回合后与真实效用的斯皮尔曼秩相关达 $\rho = 0.89 \pm 0.02$，显示在线价值估计具备可行性 [17]。然而，遗忘也可能削弱系统能力：选择性遗忘一次应用移除 9.8% 节点后，judged correctness 下降 1.6 点 [16]；记忆规范化研究显示，全规范化记忆的情感一致性改善在多重比较校正后不再显著，事实漂移在任何校正水平下均不显著，作者明确将其定位为探索性发现 [21]。这表明更新与遗忘机制在提升一致性的同时，可能引入信息损失风险，需在价值估计与保留策略之间谨慎权衡 [16, 17, 21]。

7.4 RQ5：现有评测框架能否揭示长期记忆的真实能力?

现有评测框架已在覆盖维度上取得显著进展，但对长期记忆真实能力的刻画仍不充分。LoCoMo 将对话规模扩展至约 16K tokens、588.2 turns、27.2 sessions，揭示了长上下文 LLM 与 RAG 在时间与因果动态理解上的显著落后 [31]。LongMemEval 明确将知识更新与弃答纳入五大核心能力 [33]。Memora 则进一步指出，LoCoMo 中 94% 的评估问题只需不超过 2 个此前会话的证据，LongMemEval 中该比例为 85%，显示既有基准偏重浅层检索而缺乏记忆整合压力 [32]。成本感知评测表明，长期记忆可将依赖任务成功率从无记忆的 0.00 提升至 0.55–1.00，但嵌入检索在事实变化时表现不稳定（0.30–0.95），且代理仅在 55% 的时间对正确检索值采取行动 [36]。操作级幻觉评测 HaluMem 则揭示，现有系统倾向于在抽取和更新阶段产生并累积幻觉，再向问答阶段传播 [24]。这些证据共同指向一个结论：当前评测正向更细粒度的记忆操作和可靠性维度演进，但“记忆何时真正帮助、何时引入危害”仍缺乏系统化的成本—收益度量 [24, 32, 36]。

7.5 RQ4：可靠性与安全风险如何约束记忆系统的设计?

可靠性与安全风险已成为长期记忆系统不可回避的设计约束。在非恶意可靠性方面，来源感知系统 Agent Zero Memory 通过引用锁纪律在 LongMemEval 上达 95.60%，较此前最强系统提升 +0.73 分 [26]。多智能体错误传播研究显示，幻觉检测率从 Stage 1 的 72.0% 单调下降至 Stage 4 的 50.9%，末端检查仅改善 2.3 个百分点 [23]。信息压缩的统一速率—失真视角进一步指出，查询无关压缩的有效每查询预算会被查询分布熵削减，导致快照式方法在查询分布变化时性能塌陷 [27]。在安全投毒方面，MemPoison 显示选择性记忆机制可被绕过，攻击成功率最高达 0.95[28]；而记忆投毒防御在良性流量中亦有代价——读取端防御使核心准确率下降 4.4 点，33.6% 的合法记忆被误隔离 [30]。

安全综述进一步将长期记忆界定为“可写、跨会话持久”的新安全基底，并指出保留策略可能意外保留对抗性条目而丢弃合法条目 [1]。综合而言，可靠性与安全约束要求记忆系统在来源验证、写入控制与良性效用之间寻找平衡，单一环节的强化不足以应对传播链上的综合风险 [1, 23, 26, 30]。

参考文献

[1] Zehao Lin, Xixuan Hao, Renyu Fu, Shaobo Cui, Kai Chen, Chunyu Li, Zhiyu Li, and Feiyu Xiong. A Survey on Long-Term Memory Security in LLM Agents: Attacks, Defenses, and Governance Across the Memory Lifecycle. arXiv:2604.16548, 2026.

[2] Andrew Zhao, Daniel T. Huang, Quentin Xu, Matthieu Gaetan Lin, Yong-Jin Liu, and Gao Ming Huang. ExpeL: LLM Agents Are Experiential Learners. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2024. doi: 10.1609/aaai.v38i17.29936.

[3] Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. MemGPT: Towards LLMs as Operating Systems. arXiv:2310.08560, 2023.

[4] Joon-Sung Park, Joseph O'Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative Agents: Interactive Simulacra of Human Behavior. `https://openalex.org/W4387835442`, 2023.

[5] Ali Modarressi, Ayyoob Imani, Mohsen Fayyaz, and Hinrich Schütze. RET-LLM: Towards a General Read-Write Memory for Large Language Models. arXiv:2305.14322, 2023.

[6] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. arXiv:2504.19413, 2025.

[7] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-Mem: Agentic Memory for LLM Agents. arXiv:2502.12110, 2025.

[8] Theodore R. Sumers, Shunyu Yao, Karthik Narasimhan, and Thomas L. Griffiths. Cognitive Architectures for Language Agents. arXiv:2309.02427, 2023.

[9] Ahmad Yehia, Aly O. Abdelkareem, Islam Ahmed, Hesham Omran, Khaled Alashmouny, Christian Claudel, and Abduallah Mohamed. Mem++: Non-Destructive Memory for Long-Term Organizational LLM Agents. arXiv:2610.02002, 2026.

[10] Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A Temporal Knowledge Graph Architecture for Agent Memory. arXiv:2501.13956, 2025.

[11] Hanqi Jiang, Junhao Chen, Yi Pan, Ling Chen, Weihang You, Yifan Zhou, Ruidong Zhang, Yohannes Abate, and Tianming Liu. Synapse: Empowering LLM Agents with Episodic-Semantic Memory via Spreading Activation. https://openalex.org/W7166862442, 2026.

[12] Shuqi Cao, Jingyi He, and Fei Tan. HiGMem: A Hierarchical and LLM-Guided Memory System for Long-Term Conversational Agents. https://openalex.org/W7166891029, 2026.

[13] Yu Wang and Xi Chen. MIRIX: Multi-Agent Memory System for LLM-Based Agents. arXiv:2507.07957, 2025.

[14] Fengrong Wan, Chengcan Wu, and Ningtao Lyu. SodaMem: Evidence-Grounded Temporal Graph Memory for LLM Agents. arXiv:2608.08055, 2026.

[15] Zijie Dai, Shiyuan Deng, Sheng Guan, Yizhou Tian, Xin Yao, Xiao Yan, and James Sheung-Chak Cheng. RecMem: Recurrence-based Memory Consolidation for Efficient and Effective Long-Running LLM Agents. https://openalex.org/W7166837919, 2026.

[16] Theo Rusu, Sourena Khanzadeh, and Manar H. Alalfi. Selective Forgetting: A Graph-Based Memory Framework for Long-Term LLM Agents. arXiv:2608.28978, 2026.

[17] Baris Simsek. When to Forget: A Memory Governance Primitive. arXiv:2604.12007, 2026.

[18] Beining Wu, Zihao Ding, J W Huang, and Yanxiao Zhao. Forget to Improve: On-Device LLM-Agent Continual Learning via Budget-Curated Memory. arXiv:2606.25115, 2026.

[19] Yuhang Li and Yuchen Li. What Should an Agent Forget? Separating What Is Stored from What Is Used. arXiv:2609.10263, 2026.

[20] Yuanyi Song, Yukai Wang, Xinbei Ma, Zhihui Fu, Jianghao Lin, Weiwen Liu, Jun Wang, Huarong Deng, Yong Yu, and Weinan Zhang. Retrieval-Driven Memory Reconsolidation for Long-Term LLM Agents. arXiv:2609.16053, 2026.

[21] Amit Vadnere and Aishwarya Lonarkar. Memory Canonicalization: A Framework and Benchmark for Cross-Model Drift in Persistent LLM Memory. arXiv:2610.05124, 2026.

[22] Haoran Sun, Zekun Zhang, and Shaoning Zeng. Preference-Aware Memory Update for Long-Term LLM Agents. `https://openalex.org/W4417157534`, 2026.

[23] Prabhjot Singh and Bhushan Pawar. The Hallucination Snowball: Modeling Error Propagation as State Transitions in Multi-Agent LLM Pipelines. arXiv:2608.14588, 2026.

[24] Ding Chen, Simin Niu, Kehang Li, Peng Liu, Xiangping Zheng, Bo Tang, Xinchi Li, Feiyu Xiong, and Zhiyu Li. HaluMem: Evaluating Hallucinations in Memory Systems of Agents. arXiv:2511.03506, 2025.

[25] Zi Wang, Xingqiao Wang, Emmanuel Addai, Devika Ambekar, and Xiaowei Xu. The Right Memory in the Wrong Context: Verifying Retrieval Admissibility in Long-Term Agent Memory. arXiv:2610.07309, 2026.

[26] Ming Wu and Pengyuan Zhu. Agent Zero Memory: Provenance-Aware Long-Term Memory for LLM Agents. arXiv:2608.29606, 2026.

[27] Ashwin Gerard Colaco and Nada Lahjouji. What to Keep, What to Forget: A Rate–Distortion View of Memory Compaction in LLMs and Agents. arXiv:2607.08032, 2026.

[28] Hongtao Wang, Se Yang, Yu Chen, and Puzhuo Liu. MemPoison: Bypassing Selective Memory Mechanisms to Plant Backdoors in LLM Agents. arXiv:2605.29960, 2026.

[29] Balachandra Devarangadi Sunil, Isheeta Sinha, Piyush Maheshwari, Shantanu Todmal, Shreyan Mallik, and S. M. Mishra. Memory Poisoning Attack and Defense on Memory Based LLM-Agents. arXiv:2601.05504, 2026.

[30] Pritom Bhowmik. The Price of Safety: Benign-Case Utility and Token Overhead of Memory-Poisoning Defenses in LLM Agents. arXiv:2609.22818, 2026.

[31] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating Very Long-Term Conversational Memory of LLM Agents. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024. doi: 10.18653/v1/2024.acl-long.747.

[32] Md Nayem Uddin, Kumar Shubham, Eduardo Blanco, Chitta Baral, and Gengyu Wang. From Recall to Forgetting: Benchmarking Long-Term Memory for Personalized Agents. https://openalex.org/W7166889077, 2026.

[33] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. arXiv:2410.10813, 2024.

[34] Yuanchen Bei, Tianxin Wei, Xuying Ning, Yanjun Zhao, Zhining Liu, Xiao Lin, Yada Zhu, Hendrik F. Hamann, Jingrui He, and Hanghang Tong. Mem-Gallery: Benchmarking Multimodal Long-Term Conversational Memory for MLLM Agents. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2026. doi: 10.18653/v1/2026.acl-long.1892.

[35] Haoran Tan, Zeyu Zhang, Man Chen, Xu Chen, Quanyu Dai, and Zhenhua Dong. MemBench: Towards More Comprehensive Evaluation on the Memory of LLM-based Agents. https://openalex.org/W4412887782, 2025.

[36] Shweta Mishra and Shashank Mishra. When Does Memory Help? A Cost-Aware Evaluation of Long-Term Memory in Tool-Using LLM Agents. arXiv:2609.05441, 2026.

[37] Zhiyu Shen, Ziming Wu, Fu-Ming Lai, Shaobing Lian, and Yanghui Rao. Mem-Builder: Reinforcing LLMs for Long-Term Memory Construction via Attributed Dense Rewards. https://openalex.org/W7123371499, 2026.

[38] Wanjun Zhong, Lianghong Guo, Qiqi Gao, He Ye, and Yanlin Wang. MemoryBank: Enhancing Large Language Models with Long-Term Memory. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2024. doi: 10.1609/aaai.v38i17.29946.

[39] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: language agents with verbal reinforcement learning. arXiv:2303.11366, 2023.

表 1: 研究谱系中的明确关系（逐边核查证据后裁定；仅 “提到某论文” 或论文名称相近不构成关系，无证据的边已删除）

后续工作	涉及对象	关系性质	证据（原文定位）
AMem	LoCoMo	以该基准评测	证据: ’we utilize the LoCoMo data’（pdf:p5 §4.1）
Mem0	LoCoMo	以该基准评测	证据: LOCOMO 上 LLM-as-a-Judge 相对 OpenAI +26%（pdf:p1 Abstract）
Zep	MemGPT	以其提出的基准评测并比较	证据: ’DMR benchmark, which the MemGPT team established’, Zep 94.8% vs 93.4%（pdf:p1 Abstract）
Zep	LongMemEval	以该基准评测	证据: ’validated through the more challenging LongMemEval benchmark’（pdf:p1 Abstract）
LongMemEval	MemoryBank	比较／讨论	证据: Table 1 指出含 MemoryBank 的既有 QA 基准缺失跨会话综合/更新推理等能力（pdf:p3）——非使用其评测
LongMemEval	LoCoMo	比较／讨论	证据: ’LoCoMo···also fail to evaluate recall of assistant-provided information’（pdf:p2 §2）——非使用其评测
SelectiveForgetting	GenAgents	沿用其设计	证据: 以记忆流构建持久图，引 Park et al. 2023（pdf:p1/p2）
SelectiveForgetting	LongMemEval	以该基准评测	证据: ’On LongMemEval, the graph does not out-perform···’（pdf:p1 Abstract）
Reconsolidation	LongMemEval	以该基准评测	证据: ’achieves···65.11% on LongMemEval’（pdf:p1 Abstract）
HaluMem	LongMemEval	比较／讨论	证据: 总结 LongMemEval 等为端到端黑盒评测、无法归因操作级幻觉（pdf:p5 §2.2）——非使用其评测