作业目标：为什么需要证据与人工核验

- 任务：前沿问题文献综述（ 30 篇真实文献）+ 智能体完成综述
- 选题：LLM 智能体的**跨会话外部记忆**——组织、更新、可靠性
- 两条底线：**引用可回查**（逐字验证拦截 360 次改写）与 **人工核验**（智能体不代签）

智能体架构与自适应工具选择

- 协调 Agent：观察 RQ 覆盖缺口 $\rightarrow$ 选择工具 $\rightarrow$ 执行 $\rightarrow$ 记录
- 工具层：OpenAlex/Crossref/arXiv 检索 · DOI/arXiv ID 三重键去重 · PDF 页级提取 · 证据/陈述/记忆事件溯源
- 持久化：追加式 JSONL，跨运行可恢复；记忆四类双状态（valid/trust 分离，supersedes 链保留历史）
- 两层形态：协调器回合（自主决策）+ 批处理管线（规模化深读）

一条真实的“论文—证据—陈述”路径

反幻觉验证（代码强制，不依赖模型自觉）

- 摘录提交 $\rightarrow$ 剔除空白/连字符的字符签名必须与所指页**连续匹配**
- 改写/省略号/凭记忆复述/表格拼接 $\Rightarrow$ 拒绝并返回最似原文供自纠
- 实战：拦截 360 次（协调器 258 + 批处理 102），0 条被拒摘录入库；独立抽查 4/4 摘录逐字在标注页

一条真实的“论文—证据—陈述”路径

反幻觉验证（代码强制，不依赖模型自觉）

- 摘录提交 $\rightarrow$ 剔除空白/连字符的字符签名必须与所指页**连续匹配**
- 改写/省略号/凭记忆复述/表格拼接 $\Rightarrow$ 拒绝并返回最似原文供自纠
- 实战：拦截 360 次（协调器 258 + 批处理 102），0 条被拒摘录入库；独立抽查 4/4 摘录逐字在标注页

两次真实自主决策（runs/ 日志可回查）

- 缺口驱动：观察到 RQ1/RQ5 证据不足，**自选** 7 个补检检索词（如 “memory vs context window RAG parametric knowledge”）
- 诚实失败：无法枚举证据 ID 时拒绝编造，报告工具缺口并提出改进

小规模评估、失败案例与人工验证职责

任务完成度	A（无记忆）	B（注入）	C（结构化）
跨会话恢复	0/3	3/3	3/3
跨运行（两阶段真实）	0/3	3/3	1/3
合计	**2/12**	**12/12**	**9/12**

- 诚实结论：小场景**上下文注入（B）最好**；结构化记忆暴露动作缺失与过度确定两类失败（已固化回归测试）；无记忆基线以编造补偿
- 判分核对事实/动作/引用来源/确定性——不再用关键词命中判成功

长期记忆的核心问题与研究边界

- 长上下文 $\neq$ 记忆：会话内召回，无跨会话持久写入
- 静态 RAG $\neq$ 记忆：单查询检索，无读写闭环
- 参数知识 $\neq$ 记忆：推理时不可精确更新
- 五个研究问题：RQ1 定义边界 · RQ2 组织使用 · RQ3 更新遗忘 · RQ4 可靠性 · RQ5 评测

研究脉络与主要方法类别

检索到日志的演进（谱系图，边 = 文献明确引用关系）

- 2023 奠基：记忆流 + 三因子检索（Generative Agents）· 上下文工程（MemGPT 分页/中断）· 语言化经验（Reflexion/ExpeL）
- 2024–25 组织化：结构化图（A-Mem/HippoRAG 思路）· 时间知识图（Zep）· 记忆操作（Mem0 ADD/UPDATE/DELETE/NOOP）
- 2026 前沿：遗忘治理（选择性遗忘/When to Forget）· 可靠性（provenance/信任分数）· 效率（递归巩固/率失真压缩）

记忆更新、冲突与可靠性的主要发现

- **遗忘有效且便宜**：图记忆一次剪枝移除 9.8% 节点/9.5% 存储，token F1 变化 +0.001（CI 含 0）——但 “图结构优于向量” 被证伪（LongMemEval 上 F1 0.417 vs 0.468）
- **检索到 用得上**：代理仅 55% 时间对正确检索值采取行动，忽略率 0.45–0.53
- **错误会滚雪球**：记忆幻觉（HaluMem）与错误传播（状态转移雪球）是独立于攻击的可靠性问题
- **安全有代价**：记忆防御在良性场景损失效用并增加 token 开销

评测缺口、主要挑战和结论

- 评测缺口：LoCoMo 94% 问题仅需 2 个会话；“更新正确性” 与 “何时记忆真正有帮助” 缺统一基准
- 挑战：时效与冲突处理 · 错误传播的定量刻画 · 成本-收益报告不统一
- 结论：长期记忆研究正从 “存得下” 转向 “信得过”——更新正确性与错误控制是核心开放问题